



Universidad de  
**los Andes** >

FACULTAD  
DE INGENIERÍA  
Y CIENCIAS  
APLICADAS

## **Aprendizaje de Maquinas (ML)**

### **Tarea 2:**

### **Redes Convolucionales**

**Alumno:**

Raúl Duhalde Errázuriz

**Profesores:**

José M. Saavedra Rondo

Macarena Soto

**Ayudantes:**

Tomas de la Sota

**Deadline:**

Viernes 12 de mayo, 2023, 23:50 hrs

## Índice

<b>Índice</b>	<b>1</b>
<b>1. Introducción:</b>	<b>2</b>
<b>2. Desarrollo:</b>	<b>3</b>
<b>3. Resultados Experimentales y Discusión:</b>	<b>4</b>
3.1. Resultados del modelo MLP en QuickDraw-10 dataset:	4
3.2. Resultados del modelo CNN en QuickDraw-10 dataset:	7
3.3. Resultados del modelo MLP en QuickDraw-Animals dataset:	11
3.4. Resultados del modelo CNN en QuickDraw-Animals dataset:	13
<b>4. Conclusiones:</b>	<b>15</b>
<b>Preguntas</b>	<b>16</b>

## **1. Introducción:**

En este informe, presentaremos los resultados experimentales y la discusión correspondiente de dos modelos de redes neuronales convolucionales (CNN) entrenados en el conjunto de datos QuickDraw-Animals y el conjunto de datos QuickDraw-10. El objetivo de estos modelos es identificar el tipo de animal a partir de dibujos hechos a mano alzada y para el conjunto QuickDraw-10 identificar distintos elementos tales como castillos, controles remotos etc. Además, describiremos el problema de clasificación de dibujos y compararemos dos enfoques: un modelo MLP y una red convolucional.

## **2. Desarrollo:**

Para abordar el problema de clasificación de dibujos, se entrenaron dos modelos con diferentes arquitecturas. El primer modelo, MLP, es una red neuronal con capas ocultas configurables. Por otro lado, el segundo modelo se basa en una red convolucional inspirada en la estructura utilizada en el conjunto de datos MNIST. Este último modelo aprovecha la estructura espacial de las imágenes y es capaz de capturar características importantes para la clasificación.

El desarrollo del experimento incluyó el diseño e implementación de los programas necesarios. Utilizamos el conjunto de datos QuickDraw-10 y QuickDraw-Animales, que contiene imágenes de entrenamiento y prueba. Preprocesamos el conjunto de datos, normalizando los valores de píxeles en el rango  $[0, 1]$ . Luego, construimos los modelos MLP y CNN utilizando la biblioteca TensorFlow y los compilamos con las métricas de pérdida y precisión apropiadas. Entrenamos cada modelo con los datos de entrenamiento y evaluamos su rendimiento utilizando los datos de prueba.

### 3. Resultados Experimentales y Discusión:

En esta sección, presentaremos los resultados obtenidos y analizaremos el rendimiento de los modelos MLP y CNN en la clasificación de los dibujos del conjunto de datos QuickDraw-10 y QuickDraw-Animal

#### 3.1. Resultados del modelo MLP en QuickDraw-10 dataset:


El modelo MLP consta de una capa de entrada aplanada seguida de dos capas ocultas con activación ReLU y una capa de salida con activación softmax. Se entrenó durante 10 épocas con un tamaño de lote de 32.

Los resultados obtenidos para el modelo MLP en el conjunto de prueba QuickDraw-10 son los siguientes:


- Precisión total (Accuracy): 0.5454



*figura 1:predicciones vs actual con MLP*



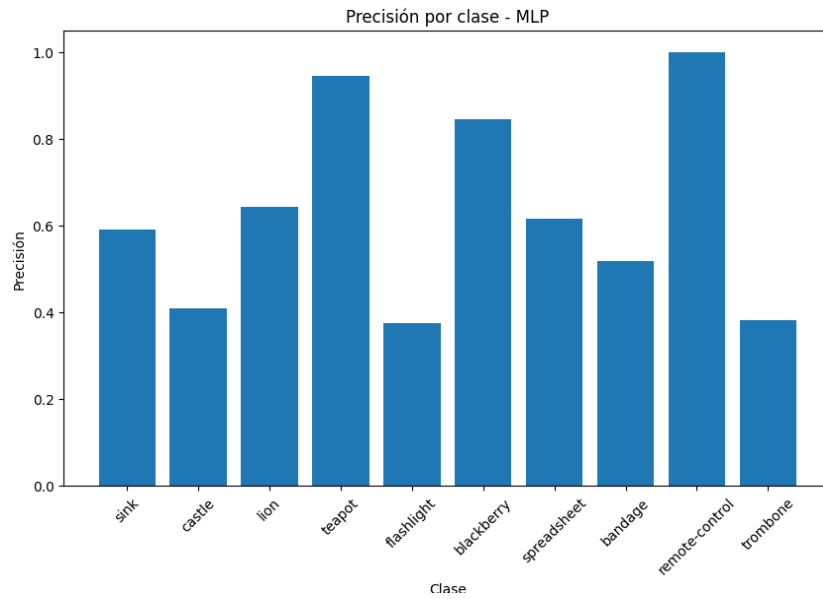
*figura 2: predicciones vs actual con MLP*



*figura 3: predicciones vs actual con MLP*


La precisión total del modelo MLP en los datos de prueba QuickDraw-10 es del 54.54%, lo que significa que el modelo clasificó correctamente el 54.54% de las imágenes de prueba.

A continuación, analizaremos la precisión por clase y mostraremos un gráfico de barras que muestra esta métrica:



*Figura 4 :Gráfico de barras con la precisión por clase del modelo MLP*

La matriz de confusión del modelo MLP en los datos de prueba QuickDraw-10 es la siguiente:



*figura 5: Matriz de confusión del modelo MLP*


En la matriz de confusión, podemos observar el desempeño del modelo MLP en la clasificación de cada clase. Se puede notar que algunas clases tienen un mejor desempeño que otras, lo que indica que el modelo tiene dificultades para distinguir ciertos tipos de dibujos.

### 3.2. Resultados del modelo CNN en QuickDraw-10 dataset:

El modelo CNN es una red convolucional simple inspirada en la arquitectura utilizada para el conjunto de datos MNIST. Consiste en capas de convolución, capas de pooling y capas densas. Se entrenó durante 10 épocas con un tamaño de lote de 32.

Los resultados obtenidos para el modelo CNN en el conjunto de prueba QuickDraw-10 son los siguientes:

- Precisión total (Accuracy): 0.8595

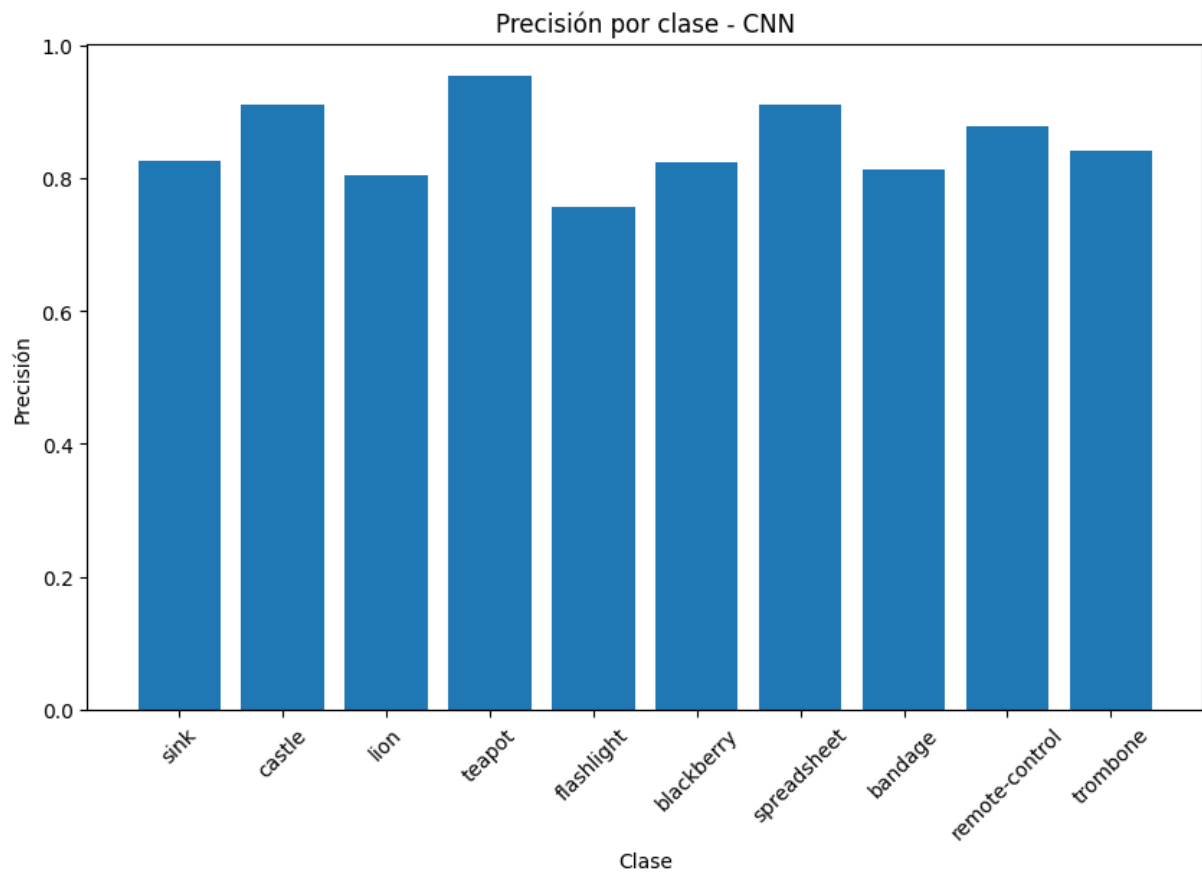


*figura 6: predicciones vs actual con CNN*

La precisión total del modelo CNN en los datos de prueba QuickDraw-10 es del 85.95%, lo que indica que el modelo clasificó correctamente el 85.95% de las imágenes de prueba.




A continuación, analizaremos la precisión por clase y mostraremos un gráfico que muestra esta métrica:



*figura 7: Gráfico de barras con la precisión por clase del modelo CNN*

La matriz de confusión del modelo CNN en los datos de prueba QuickDraw-10 es la siguiente:




*figura 8: Matriz de confusión del modelo CNN*

En la matriz de confusión, podemos observar el desempeño del modelo CNN en la clasificación de cada clase. Se puede notar que el modelo CNN tiene un mejor desempeño general en comparación con el modelo MLP. Sin embargo, también existen algunas clases donde el modelo CNN tiene dificultades para realizar una clasificación precisa.

En general, los resultados indican que el modelo CNN supera al modelo MLP en términos de precisión en la clasificación de los dibujos del conjunto QuickDraw-10. La capacidad de las redes neuronales convolucionales para capturar características espaciales en las imágenes parece beneficiar la clasificación de dibujos hechos a mano.

### 3.3. Resultados del modelo MLP en QuickDraw-Animals dataset:



*figura 9: predicciones vs actual con MLP*

En el caso del modelo MLP, se entrenó durante 10 épocas y logró una precisión de 0.439 en los datos de prueba. La precisión se calcula como la proporción de muestras clasificadas correctamente en relación con el total de muestras. Para evaluar el rendimiento del modelo en cada clase, se utilizó una matriz de confusión que no se proporciona en el texto. Esta matriz muestra el número de predicciones correctas e incorrectas para cada clase en el conjunto de datos de prueba.


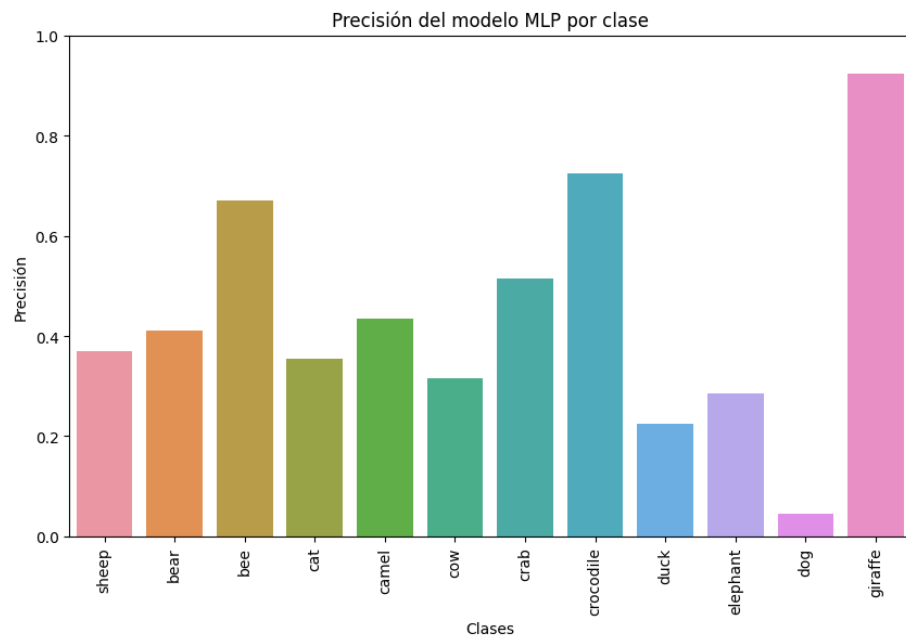



figura 10: Matriz de confusión del modelo CNN

Además, se muestra una gráfica de barras que representa la precisión del modelo MLP para cada clase en los datos de prueba. Cada barra en el gráfico representa una clase específica, y la altura de la barra indica la precisión del modelo para esa clase. Esta gráfica proporciona una visión general del rendimiento del modelo en la clasificación de cada clase, lo que puede ayudar a identificar las clases para las cuales el modelo tiene un rendimiento deficiente.



*Figura 11 :Gráfico de barras con la precisión por clase del modelo MLP*

### 3.4. Resultados del modelo CNN en QuickDraw-Animals dataset:



*figura 12: predicciones vs actual con CNN*

En el caso del modelo CNN, también se entrenó durante 10 épocas, pero logró una precisión mayor, alcanzando 0.7115 en los datos de prueba. Al igual que con el modelo MLP, se utilizó una matriz de confusión para evaluar el rendimiento del modelo en cada clase, pero no se proporciona en el texto. Esta matriz permite ver

las predicciones correctas e incorrectas para cada clase en el conjunto de datos de prueba.


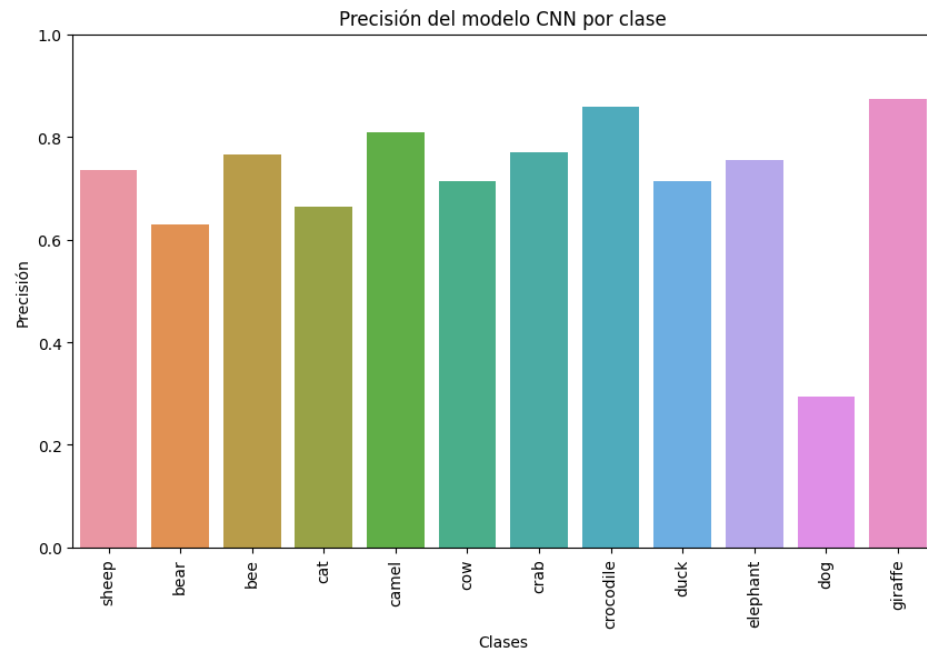


figura 13: Matriz de confusión del modelo CNN

Además, se muestra una gráfica de barras que representa la precisión del modelo CNN para cada clase en los datos de prueba. Al igual que en el caso del modelo MLP, cada barra en el gráfico representa una clase específica, y la altura de la barra indica la precisión del modelo para esa clase. Esta gráfica permite comparar el rendimiento del modelo CNN con el modelo MLP en términos de la clasificación de cada clase.



*figura 14: Gráfico de barras con la precisión por clase del modelo CNN*

En resumen, los resultados indican que el modelo CNN tiene un rendimiento superior al modelo MLP en el conjunto de datos QuickDraw-Animals, ya que logra una precisión más alta en la clasificación de las clases. La matriz de confusión y las gráficas de barras proporcionan más detalles sobre el rendimiento del modelo en cada clase específica.



#### **4. Conclusiones:**

En este trabajo, evaluamos los dos modelos de redes neuronales en la clasificación de dibujos hechos a mano. Nuestros resultados mostraron que la red convolucional superó al modelo MLP en términos de precisión. La red convolucional demostró ser más efectiva al aprovechar la estructura espacial de las imágenes y capturar características importantes para la clasificación. Estos hallazgos destacan la importancia de elegir el modelo adecuado para lograr buenos resultados en la clasificación de dibujos.

En resumen, concluimos que la arquitectura de varias capas convolucionales utilizada en la red convolucional es más efectiva que la arquitectura de una sola capa convolucional para la tarea de clasificación de dibujos de animales en el conjunto de datos QuickDraw-Animals y el conjunto de datos QuickDraw-10. Estos resultados tienen implicaciones importantes para futuras aplicaciones de clasificación de imágenes y aprendizaje automático.

## Preguntas

a) ¿Qué ocurre con una MLP en la clasificación de dibujos?

En el caso de una MLP (Multi-Layer Perceptron) en la clasificación de dibujos, los resultados pueden variar. Las MLP son modelos de redes neuronales feedforward que no tienen en cuenta la estructura espacial de los datos de imagen. Por lo tanto, pueden tener dificultades para capturar las características importantes presentes en los dibujos. En comparación con las redes convolucionales, las MLP pueden obtener resultados inferiores en términos de precisión en la clasificación de dibujos.

b) ¿Qué ocurre con una red convolucional en la clasificación de dibujos?

Las redes convolucionales son especialmente adecuadas para la clasificación de dibujos debido a su capacidad para capturar características espaciales en las imágenes. Al aplicar operaciones de convolución y pooling, las redes convolucionales pueden aprender patrones locales y globales en los dibujos, lo que les permite realizar una clasificación más precisa. En general, se espera que una red convolucional tenga un mejor desempeño en la clasificación de dibujos en comparación con una MLP.

c) ¿Cuál de los conjuntos de datos es más desafiante?

El conjunto de datos QuickDraw-Animals parece ser más desafiante en comparación con el conjunto de datos QuickDraw-10. Esto se puede observar en las precisiones totales obtenidas por los modelos MLP y CNN en ambos conjuntos de datos. El modelo MLP alcanzó una precisión total de 54.54% en QuickDraw-10, mientras que en QuickDraw-Animals obtuvo una precisión total de 43.9%. Por otro lado, el modelo CNN logró una precisión total de 85.95% en QuickDraw-10 y 71.15% en QuickDraw-Animals. Estas cifras sugieren que la clasificación de las imágenes de animales es más desafiante en comparación con la clasificación de los dibujos en QuickDraw-10.

d) ¿Qué clases tienen un mejor desempeño en la clasificación?

Las clases con mejor desempeño varían dependiendo del conjunto de datos y el modelo utilizado. En el conjunto de datos QuickDraw-10, el modelo CNN mostró un mejor desempeño en general, con una precisión total del 85.95% siendo los mas altos "teapot", "blackberry" y "remote control". En el conjunto de datos QuickDraw-Animals, el modelo CNN también superó al modelo MLP, con una precisión total del 71.15% siendo los mas altos "giraffe", "crocodile" y "camel".

e) ¿Qué clases tienen un peor desempeño en la clasificación?

Las clases con peor desempeño también varían según el conjunto de datos y el modelo. En QuickDraw-10, las clases con peor desempeño para el modelo MLP donde “castle”, “flashlight” y “trombone” tuvieron el peor rendimiento. En QuickDraw-Animals, las clases específicas con peor desempeño para el modelo MLP fueron “dog”, “duck” y “elephant” tuvieron el peor rendimiento.

f) ¿Por qué el modelo tiene o no tiene un buen desempeño?

El desempeño del modelo puede estar influenciado por varios factores, como la arquitectura del modelo, el conjunto de datos utilizado, el tamaño del conjunto de entrenamiento, el número de épocas de entrenamiento, entre otros. En este caso, se observa que el modelo CNN superó al modelo MLP en términos de precisión en ambos conjuntos de datos. Esto podría deberse a que el modelo CNN tiene la capacidad de capturar características espaciales en las imágenes gracias a su estructura convolucional, lo que resulta beneficioso para la clasificación de dibujos hechos a mano. Por otro lado, el modelo MLP puede tener limitaciones para capturar estas características y, por lo tanto, tiene un desempeño inferior. Sin embargo, es importante tener en cuenta que los resultados y conclusiones se basan en la información proporcionada en el texto, y no se detallan aspectos específicos del desempeño de cada modelo en las clases individuales o las razones exactas detrás del desempeño observado.